



UNIVERSITÀ POLITECNICA DELLE MARCHE

Facoltà di Ingegneria

Corso di Laurea Triennale in Ingegneria Informatica e dell'Automazione

PROGETTO DI DATA SCIENCE

Ames Housing: Data-Driven Modeling and Market
Segmentation

**Ames Housing: Modellazione Data-Driven
e Segmentazione del Mercato**

Docente:

Prof. Domenico Ursino

Componenti del gruppo:

Meloccaro Lorenzo
Suarez Sanchez Yassir Flavio
La Porta Domenico

Anno Accademico 2025/2026

Indice

1 Introduzione

- 1.1 Obiettivi del Progetto
- 1.2 Struttura del Lavoro
- 1.3 Motivazioni e Contesto

2 Il Dataset: Ames Housing

- 2.1 Descrizione del Dataset
- 2.2 Analisi Esplorativa Preliminare

3 ETL e Preprocessing

- 3.1 Introduzione al Preprocessing
- 3.2 Pulizia Dati Preliminare
- 3.3 Feature Engineering
- 3.4 Trasformazione della Variabile Target
- 3.5 Identificazione delle Tipologie di Feature
- 3.6 Gestione degli Outlier
- 3.7 Encoding delle Variabili Categoricali
- 3.8 Standardizzazione
- 3.9 Dataset Finale Post-Preprocessing

4 Feature Selection

- 4.1 Motivazioni
- 4.2 Approccio Metodologico e Mutual Information
- 4.3 Risultati della Feature Selection

5 Task di Regressione

- 5.1 Definizione del Problema
- 5.2 Modelli Considerati
- 5.3 Strategia di Valutazione
- 5.4 Risultati e Confronto tra Modelli
- 5.5 Analisi degli Errori e Discussione

6 Task di Clustering

- 6.1 Obiettivo e Approccio
- 6.2 Preparazione dei Dati per il Clustering
- 6.3 K-Means Clustering
- 6.4 Valutazione del Clustering
- 6.5 Interpretazione dei Cluster e Validazione Esterna
- 6.6 Confronto con DBSCAN
- 6.7 Discussione

7 Task di Classificazione

- 7.1 Obiettivo e Strategia
- 7.2 Creazione delle Classi Target
- 7.3 Bilanciamento delle Classi
- 7.4 Configurazione del Modello e Validazione
- 7.5 Risultati e Metriche di Valutazione
- 7.6 Analisi della Matrice di Confusione
- 7.7 Discussione e Implicazioni

8 Sintesi Comparativa

- 8.1 Confronto delle Performance tra i Task
- 8.2 Punti di Forza dei Diversi Paradigmi

8.3 Idoneità del Dataset ai Diversi Task

8.4 Key Findings Cross-Task

8.5 Raccomandazioni Strategiche

9 Conclusioni

9.1 Riepilogo del Lavoro Svolto

9.2 Valutazione Complessiva del Dataset

9.3 Contributi Metodologici e Limitazioni

1 Introduzione

1.1 Obiettivi del Progetto

Il presente lavoro si propone di condurre un'analisi esaustiva del dataset *Ames Housing* attraverso l'implementazione di tre distinte metodologie di apprendimento automatico: **regressione supervisionata**, **clustering non supervisionato** e **classificazione multi-classe**. L'obiettivo primario consiste nel valutare l'idoneità intrinseca del dataset rispetto a ciascuna delle tre tipologie di task, identificando contestualmente i punti di forza e le criticità che emergono dall'applicazione delle diverse tecniche analitiche.

La motivazione alla base di questo studio risiede nella necessità di comprendere in modo approfondito come le caratteristiche strutturali di un dataset influenzino le performance dei modelli predittivi. A tal fine, si è scelto di adottare un approccio metodologico rigoroso che prevede l'utilizzo di tecniche consolidate di preprocessing, feature engineering e validazione incrociata, al fine di garantire la robustezza e la riproducibilità dei risultati.

Nello specifico, per il **task di regressione** si intende predire il valore di vendita delle proprietà immobiliari (*SalePrice*) a partire da un insieme selezionato di feature descrittive, confrontando quattro modelli di complessità crescente. Per quanto concerne il **clustering**, l'obiettivo è individuare raggruppamenti naturali all'interno dei dati che possano rivelare pattern latenti relativi alle caratteristiche abitative, operando in assenza di supervisione. Infine, il task di **classificazione** mira a categorizzare le proprietà in classi di prezzo discrete (Low, Medium, High), permettendo di valutare la separabilità delle diverse fasce di mercato.

1.2 Struttura del Lavoro

La struttura della presente relazione è stata concepita per guidare il lettore attraverso un percorso analitico graduale e metodico. Dopo questa sezione introduttiva, il Capitolo 2 presenta una descrizione dettagliata del dataset Ames Housing, includendo un'analisi esplorativa preliminare che mette in luce le caratteristiche salienti dei dati e le problematiche da affrontare.

Il Capitolo 3 è dedicato interamente alla fase di ETL e preprocessing, illustrando le strategie adottate per la pulizia dei dati, la gestione dei valori mancanti, il trattamento degli outlier e la trasformazione delle variabili. Particolare attenzione viene riservata alle operazioni di feature engineering, fondamentali per arricchire il contenuto informativo del dataset, e all'encoding delle variabili categoriche, con strategie differenziate per cardinalità bassa ed elevata.

Il Capitolo 4 descrive il processo di feature selection basato sul calcolo della mutual information. I Capitoli 5, 6 e 7 presentano rispettivamente i risultati dei task di regressione, clustering e classificazione, con un'analisi critica delle performance ottenute. Il Capitolo 8

propone una sintesi comparativa dei tre task, mentre il Capitolo 9 trae le conclusioni generali del lavoro.

1.3 Motivazioni e Contesto

Il dataset *Ames Housing*, introdotto da De Cock nel 2011 [1], rappresenta un benchmark ampiamente riconosciuto nell'ambito del machine learning applicato al settore immobiliare. È stato concepito come alternativa moderna al celebre Boston Housing Dataset, offrendo un numero significativamente maggiore di osservazioni e feature, nonché una migliore qualità complessiva dei dati.

La scelta di questo dataset è stata dettata da molteplici considerazioni. La ricchezza informativa delle feature disponibili permette di testare in modo efficace le capacità dei diversi algoritmi nel catturare relazioni complesse tra variabili. La presenza di variabili sia numeriche che categoriche, con diversi livelli di cardinalità, consente di valutare l'efficacia delle tecniche di encoding e preprocessing. Infine, la natura del problema predittivo presenta una rilevanza pratica immediata e consente il confronto con intuizioni di dominio consolidate nel settore immobiliare.

Un aspetto cruciale del presente lavoro riguarda l'adozione di un framework valutativo completo che integra metriche quantitative e considerazioni qualitative. Per il task di regressione vengono utilizzati il coefficiente di determinazione (R^2) e il Root Mean Squared Error (RMSE). Per il clustering si impiegano il Silhouette Score e il Davies–Bouldin Index. Per la classificazione, l'F1-score pesato risulta particolarmente adatto in presenza di classi multiple. L'approccio adottato prevede l'utilizzo sistematico della validazione incrociata k-fold con $k=5$, tecnica che riduce il rischio di overfitting e fornisce una stima più robusta delle performance di generalizzazione [6].

2 Il Dataset: Ames Housing

2.1 Descrizione del Dataset

2.1.1 Fonte e Caratteristiche Generali

Il dataset *Ames Housing* contiene informazioni dettagliate relative a transazioni immobiliari avvenute nella città di Ames, Iowa, tra il 2006 e il 2010. Questa risorsa è stata originariamente compilata da Dean De Cock per scopi didattici e di ricerca, con l'intento di fornire un'alternativa al Boston Housing Dataset che presentasse caratteristiche più moderne e una maggiore ricchezza descrittiva [1].

2.1.2 Dimensioni e Struttura

Il dataset è composto da **2.930 osservazioni** e **82 variabili**, di cui 43 categoriche e 39 numeriche. Le variabili possono essere suddivise in quattro macro-categorie: caratteristiche fisiche dell'immobile (superfici, dimensioni, numero di vani), aspetti qualitativi (qualità costruttiva, condizione generale), dotazioni e servizi (garage, seminterrato, piscina), e contesto urbanistico (quartiere, zona).

Tale eterogeneità rappresenta una sfida significativa per l'analisi, rendendo necessarie tecniche avanzate di preprocessing e feature engineering. Un aspetto critico riguarda la presenza di valori mancanti in 19 feature, con percentuali che variano da valori trascurabili fino a oltre l'80% per alcune variabili relative a dotazioni rare come piscine e vialetti. In molti casi, il valore mancante non rappresenta una lacuna informativa, bensì l'assenza della caratteristica stessa.

2.1.3 Variabile Target: SalePrice

La variabile *SalePrice* rappresenta il prezzo di vendita finale dell'immobile espresso in dollari statunitensi. Le statistiche descrittive principali sono le seguenti:

Statistica	Valore
Media	\$180.921
Mediana	\$163.000
Deviazione standard	\$79.442
Minimo	\$34.900
Massimo	\$755.000
Skewness	1.88
Kurtosis	6.54

La distribuzione presenta una marcata **asimmetria positiva** (skewness = 1.88) e una kurtosis elevata (6.54), indicativa di code pesanti e presenza di valori estremi. La media risulta superiore alla mediana di oltre \$17.000, segnale inequivocabile di una distribuzione

con coda destra pronunciata: la maggioranza delle proprietà si concentra nella fascia \$100k–\$250k, mentre un numero limitato di abitazioni di pregio raggiunge valori fino a \$755.000, trainando verso l'alto la media. Tali caratteristiche suggeriscono fortemente l'opportunità di applicare una trasformazione logaritmica per migliorare le proprietà statistiche della variabile target e ridurre l'influenza sproporzionata dei valori estremi sulla funzione di perdita dei modelli.

2.2 Analisi Esplorativa Preliminare

2.2.1 Distribuzione della Variabile Target

La Figura 1 illustra la distribuzione di *SalePrice* attraverso sei rappresentazioni complementari: l'istogramma della distribuzione originale, il boxplot, l'istogramma della distribuzione log-trasformata, il Q-Q plot per la verifica della normalità, la stima kernel della densità (KDE) e lo scatter index vs value per rilevare pattern temporali o anomalie localizzate. Il titolo riporta automaticamente la skewness prima e dopo la trasformazione logaritmica, evidenziando la riduzione da 1.88 a circa 0.12 ottenuta con $\log_{10}(\text{SalePrice})$.




Figura 1: Distribuzione della variabile target *SalePrice* — analisi multidimensionale con distribuzione originale, log-trasformata, Q-Q plot, KDE e scatter.

2.2.2 Valori Mancanti

L'analisi dei valori mancanti rivela una struttura non casuale. Le feature con la percentuale più elevata — *PoolQC*, *MiscFeature*, *Alley*, *Fence* — presentano mancanti strutturali: l'assenza del valore rappresenta con alta probabilità l'assenza della caratteristica stessa (assenza di piscina, di vicolo, di recinzione). Per le variabili numeriche come *LotFrontage* e *GarageYrBlt*, invece, i mancanti sono imputabili a incompletezze di registrazione. La Figura 2 illustra la distribuzione dei valori mancanti per le top-30 feature.




Figura 2: Percentuale di valori mancanti per feature, ordinate in senso decrescente.

2.2.3 Struttura delle Correlazioni

La Figura 2 mostra le top-15 feature numeriche per correlazione assoluta di Pearson con *SalePrice* e la relativa matrice di correlazione. Le feature più correlate risultano *Overall Qual* (qualità costruttiva complessiva, $r \approx 0.79$) e *GrLivArea* (superficie abitabile, $r \approx 0.71$), confermando l'importanza delle dimensioni e della qualità nel determinare il valore immobiliare. La Figura 3 mostra i pairplot tra le sei feature più correlate e il target, evidenziando relazioni sostanzialmente lineari una volta applicata la trasformazione logaritmica.




Figura 3: Top-15 correlazioni con *SalePrice* (sinistra) e matrice di correlazione (destra).




Figura 4: Scatter plot con retta di regressione tra le sei feature più correlate e SalePrice.

3 ETL e Preprocessing

3.1 Introduzione al Preprocessing

Il preprocessing dei dati costituisce una fase cruciale dell'intero processo di analisi e modellazione, il cui impatto sulle performance finali dei modelli risulta spesso comparabile, se non superiore, a quello derivante dalla scelta degli algoritmi di apprendimento automatico. La letteratura consolidata sottolinea come la qualità delle predizioni dipenda in larga misura dalla capacità di individuare e correggere anomalie nei dati, gestire correttamente i valori mancanti e trasformare le variabili in rappresentazioni numeriche adeguate [2, 3].

Nel presente lavoro, il preprocessing è stato concepito come un processo strutturato e multi-stadio, organizzato in dieci passi sequenziali. Una scelta progettuale fondamentale riguarda il mantenimento di due dataset separati per l'intera durata dell'analisi: il dataset grezzo originale (*self.df*), utilizzato esclusivamente per le visualizzazioni esplorative, e il dataset preprocessato (*self.df_preprocessed*), utilizzato per i tre task di machine learning. Questa separazione garantisce che le trasformazioni non alterino le rappresentazioni esplorative dei dati nella loro forma originale, preservando la coerenza dell'analisi descrittiva.

L'ordine di applicazione delle diverse operazioni non è arbitrario: la pulizia precede il feature engineering, che precede l'imputazione, che precede l'encoding. Questo schema garantisce che ciascuna trasformazione operi su dati già trattati nelle fasi precedenti, prevenendo la propagazione di artefatti e garantendo la coerenza dell'intero processo.

3.2 Pulizia Dati Preliminare

La prima fase operativa ha riguardato la rimozione delle colonne *Order* e *PID*, identificatori amministrativi privi di valore predittivo. La loro eventuale inclusione potrebbe indurre fenomeni di overfitting in modelli altamente flessibili che associano pattern spurii all'identificatore. Contestualmente, alcune colonne contenenti spazi nei nomi sono state rinominate in identificatori Python-compatibili, prerequisito necessario per il corretto funzionamento delle successive operazioni di encoding.

Gestione dei valori mancanti: per le variabili numeriche si è adottata l'imputazione tramite **mediana**, scelta robusta rispetto alla presenza di outlier e in grado di preservare la forma complessiva della distribuzione empirica. Per variabili come *LotFrontage* e *GarageYrBlt* questa scelta è motivata dalla distribuzione asimmetrica dei valori originali, dove la media risulterebbe distorta dalla presenza di outlier. Per le variabili categoriche si è optato per l'introduzione di una categoria esplicita denominata "**Missing**", anziché procedere con l'assegnazione della moda. Questa strategia preserva l'informazione potenzialmente associata all'assenza della caratteristica: per variabili come *PoolQC*, il valore mancante segnala con alta probabilità l'assenza della piscina, un'informazione che

sarebbe irrimediabilmente persa con la moda.

3.3 Feature Engineering

Il feature engineering rappresenta una delle componenti più rilevanti dell'intero processo di preprocessing. L'obiettivo principale consiste nell'estrarre informazione latente attraverso la combinazione e la trasformazione di variabili esistenti, generando nuove feature potenzialmente più informative. Nel presente lavoro sono state create sei nuove variabili derivate dalla conoscenza del dominio immobiliare:

- **TotalSF**: somma delle superfici di primo piano, secondo piano e seminterrato. La superficie totale è il predittore più forte del valore immobiliare secondo la letteratura economica e risulterà prima nelle feature selezionate dalla Mutual Information. La sua creazione sintetizza tre variabili correlate in un indicatore unitario più robusto.
- **HouseAge**: differenza tra anno di vendita e anno di costruzione. Fornisce una misura temporale relativa, più stabile e interpretabile rispetto all'anno assoluto di costruzione, il cui significato diminuisce col passare del tempo.
- **SinceRemod**: anni trascorsi dall'ultima ristrutturazione significativa. Cattura il deprezzamento mitigato da interventi di manutenzione, separando l'effetto dall'età anagrafica dell'edificio.
- **HasPool, HasFireplace, HasGarage**: variabili binarie (0/1) che codificano la presenza di specifiche dotazioni. Separano l'effetto discreto della presenza dall'effetto quantitativo (es. dimensione della piscina), permettendo al modello di catturarli indipendentemente.

3.4 Trasformazione della Variabile Target

L'analisi esplorativa ha evidenziato come la variabile *SalePrice* presenti una marcata asimmetria positiva ($\text{skewness} = 1.88$) e una kurtosis elevata. È stata pertanto applicata la trasformazione logaritmica:

$$\text{SalePrice}_{\log} = \log(1 + \text{SalePrice})$$

La funzione $\log_{1p}$ — ovvero il logaritmo di $(1 + x)$ — garantisce robustezza numerica anche in presenza di valori prossimi allo zero, poiché $\log(1) = 0$ evita il problema della divergenza del logaritmo in zero. Sul dataset Ames Housing, dove il prezzo minimo è \$34.900, la differenza rispetto al log semplice è trascurabile, ma l'utilizzo di $\log_{1p}$ costituisce una pratica standard di programmazione difensiva. La trasformazione riduce la skewness da 1.88 a circa 0.12, migliorando l'aderenza alla normalità e facilitando la modellazione. Tutti i modelli supervisionati adottano *SalePrice_log* come variabile target. La trasformazione viene applicata condizionatamente: solo se il valore assoluto della skewness supera la soglia di 0.75.

3.5 Identificazione delle Tipologie di Feature

A seguito del feature engineering, le variabili presenti nel dataset vengono classificate in tre categorie in base alla loro natura e cardinalità: variabili numeriche (*num_cols*), variabili categoriche a bassa cardinalità con al più 10 valori unici (*low_card*), e variabili categoriche ad alta cardinalità con più di 10 valori unici (*high_card*). La soglia di 10 corrisponde al parametro *cardinality_threshold* e può essere modificata all'istanziamento della classe. Tale categorizzazione è fondamentale per guidare le successive scelte di encoding.

3.6 Gestione degli Outlier

La gestione degli outlier è stata affrontata mediante il metodo dell'**Interquartile Range (IQR)** con strategia di clipping. Per ciascuna variabile numerica vengono calcolati i bound:

$$\text{lower} = Q1 - 1.5 \cdot \text{IQR}, \text{upper} = Q3 + 1.5 \cdot \text{IQR}$$

I valori al di fuori di tali limiti vengono riportati al bound corrispondente tramite la funzione `.clip()`. La scelta del clipping rispetto alla rimozione è motivata dalla necessità di preservare tutte le 2.930 osservazioni, eliminando il rischio di bias da campionamento selettivo. Il clipping riduce l'influenza indebita dei valori estremi sulla stima dei parametri dei modelli senza alterare la struttura del dataset.

3.7 Encoding delle Variabili Categoriche

Le variabili categoriche vengono elaborate con strategie differenziate in base alla loro cardinalità, per bilanciare informazione preservata ed efficienza computazionale.

One-Hot Encoding per bassa cardinalità (≤ 10 categorie): applicato tramite `pd.get_dummies(drop_first=True, dtype=int)`. Il parametro `drop_first=True` elimina una categoria per colonna per evitare la cosiddetta dummy variable trap, ovvero la multicollinearità perfetta che renderebbe la matrice di design singolare nei modelli lineari: con k categorie bastano $k-1$ colonne dummy, poiché l'ultima è implicitamente determinata dalle altre. Questo encoding recupera informazione predittiva rilevante da feature come KitchenQual, ExterQual, BsmtQual — tutte con correlazione con SalePrice superiore a 0.6 — che nella versione precedente dello script venivano erroneamente ignorate.

Target Encoding Out-of-Fold per alta cardinalità (> 10 categorie): per variabili come *Neighborhood* (25 quartieri), l'OHE produrrebbe 24 colonne sparse computazionalmente inefficienti. Il Target Encoding OOF associa a ciascuna categoria la media di SalePrice calcolata esclusivamente sui dati di training di ciascun fold. Questo approccio è fondamentale per evitare il data leakage: se la media fosse calcolata sull'intero dataset, ogni riga contribuirebbe al calcolo del proprio encoding, trasmettendo indirettamente al modello informazioni sul proprio prezzo durante l'addestramento. Con l'approccio OOF, ogni riga viene encodata usando solo le osservazioni degli altri fold, garantendo una stima non contaminata. Le categorie non osservate nel fold di training vengono imputate con la media globale.

3.8 Standardizzazione

Tutte le feature numeriche — incluse le colonne dummy generate dall'OHE — vengono sottoposte a standardizzazione z-score mediante StandardScaler: $z = (x - \mu) / \sigma$. La standardizzazione riconduce tutte le variabili a media zero e deviazione standard unitaria. Sebbene i modelli tree-based (Random Forest, Gradient Boosting) siano invarianti rispetto alla scala delle feature, essa è necessaria per i modelli lineari regolarizzati (Ridge, Lasso): senza standardizzazione, la penalizzazione L1/L2 agirebbe in modo disomogeneo su feature con scale differenti, distorcendo la selezione e la contrazione dei predittori.

3.9 Dataset Finale Post-Preprocessing

Al termine della pipeline, il dataset risulta composto da **2.930 righe** e **227 feature**, completamente privo di valori mancanti. Le colonne categoriche a bassa cardinalità sono state espanse in colonne dummy binarie, quelle ad alta cardinalità sono state sostituite con encoding numerici OOF, e tutte le feature numeriche sono state standardizzate. L'espansione da 82 a 227 feature è principalmente dovuta all'One-Hot Encoding, che genera colonne aggiuntive per ciascuna categoria. Questo dataset costituisce la base comune per le tre fasi successive di modellazione.

4 Feature Selection

4.1 Motivazioni

A seguito del preprocessing, il dataset presenta 227 feature disponibili. L'elevata dimensionalità introduce diversi rischi: aumento del rischio di overfitting, incremento della complessità computazionale, e presenza di rumore informativo introdotto da feature scarsamente rilevanti che possono disturbare l'apprendimento. La feature selection si rende pertanto necessaria per ridurre la dimensionalità preservando il contenuto informativo essenziale.

4.2 Approccio Metodologico e Mutual Information

È stato adottato un approccio di tipo **filter-based**, indipendente dal modello, basato sul calcolo della **Mutual Information Regression** tra ciascuna feature e la variabile target *SalePrice_log*. La mutual information misura la quantità di informazione condivisa tra due variabili aleatorie:

$$I(X; Y) = H(Y) - H(Y | X)$$

dove $H(Y)$ rappresenta l'entropia di Y e $H(Y|X)$ l'entropia condizionata. Un valore elevato indica una forte dipendenza statistica tra la feature e il target. A differenza della correlazione di Pearson, la mutual information cattura relazioni non lineari e non assume alcuna forma funzionale tra predittore e target, risultando più adatta a dataset con relazioni complesse come quello immobiliare.

Sono state selezionate le top-40 feature per MI score. Il calcolo viene effettuato esclusivamente su colonne numeriche dopo il preprocessing, usando la funzione *mutual_info_regression* di scikit-learn. Eventuali NaN residui vengono imputati con la mediana prima del calcolo.

4.3 Risultati della Feature Selection

Le dieci feature più informative risultanti dall'analisi sono:

Ran k	Feature	Interpretazione
1	TotalSF	Superficie totale (feature ingegnerizzata)
2	Overall Qual	Qualità costruttiva complessiva (scala 1–10)
3	Neighborhood_encoded	Quartiere (target encoding OOF)
4	Gr Liv Area	Superficie abitabile sopra terra
5	Garage Area	Superficie del garage
6	Year Built	Anno di costruzione

7	TotalBsmtSF	Superficie seminterrato
8	Garage Cars	Capacità garage (numero auto)
9	FirstFlrSF	Superficie primo piano
10	HouseAge	Età dell'immobile (feature ingegnerizzata)

La presenza di TotalSF in prima posizione e di HouseAge in decima — entrambe feature ingegnerizzate — conferma che il feature engineering ha generato informazione aggiuntiva reale rispetto alle variabili originali. Il Neighborhood_encoded in terza posizione evidenzia l'importanza della localizzazione geografica, catturata in modo compatto dal target encoding OOF. La distribuzione delle feature selezionate riflette la struttura fondamentale del valore immobiliare: dimensione, qualità e localizzazione.

5 Task di Regressione

5.1 Definizione del Problema

Il task di regressione ha come obiettivo la predizione del valore log-trasformato di *SalePrice* a partire dalle 40 feature selezionate. L'utilizzo della variabile target in scala logaritmica è coerente con la trasformazione applicata in fase di preprocessing e garantisce che le metriche di valutazione siano calcolate su una distribuzione più simmetrica, rendendo il confronto tra modelli più equo.

5.2 Modelli Considerati

Sono stati implementati e confrontati quattro modelli di regressione supervisionata, scelti per coprire uno spettro ampio di paradigmi algoritmici:

Ridge Regression (alpha=10.0): modello lineare con penalizzazione L2 sul quadrato dei coefficienti. La penalizzazione shrinka i coefficienti verso zero senza azzerarli, riducendo la varianza del modello in presenza di feature correlate. Con alpha=10 si adotta una regolarizzazione moderata. Ridge costituisce il baseline lineare più robusto e permette di quantificare la componente lineare delle relazioni nel dataset.

Lasso Regression (alpha=0.001, max_iter=5000): penalizzazione L1 sul valore assoluto dei coefficienti. A differenza di Ridge, Lasso può azzerare completamente alcuni coefficienti producendo un modello sparso. Con alpha molto basso si è prossimi alla regressione lineare semplice. Il parametro max_iter=5000 è necessario perché l'ottimizzazione L1 richiede più iterazioni per convergere.

Random Forest Regressor (n_estimators=200): ensemble di 200 alberi di decisione addestrati su bootstrap sample del dataset con selezione casuale delle feature a ogni split. La predizione finale è la media delle predizioni individuali. Robusto agli outlier, cattura relazioni non lineari e interazioni tra feature senza ingegnerizzarle esplicitamente.

Gradient Boosting Regressor (n_estimators=200, learning_rate=0.05, max_depth=4): ensemble sequenziale dove ogni albero corregge i residui del precedente. Il learning_rate basso (0.05) combinato con molti alberi (200) implementa lo shrinkage: ogni step contribuisce con piccola intensità, riducendo il rischio di overfitting. max_depth=4 limita la complessità di ogni albero individuale. È la configurazione standard per dataset tabulari strutturati.

5.3 Strategia di Valutazione

Le performance sono state valutate mediante validazione incrociata K-Fold con k=5, con shuffle abilitato e random_state fisso per riproducibilità. In ogni fold il modello viene addestrato su 4/5 del dataset e valutato su 1/5. Le metriche calcolate in scala logaritmica sono: coefficiente di determinazione R^2 , Root Mean Squared Error (RMSE) e Mean

Absolute Error (MAE). Al termine della cross-validation, viene addestrato un modello finale sull'intero dataset per estrarre le importanze delle feature mediante permutation importance.

5.4 Risultati e Confronto tra Modelli

Modello	R^2 medio	$\pm$ std	RMSE (log)	$\pm$ std	MAE (log)	Verdict
Ridge	0.8912	0.0217	0.1333	0.0141	0.0884	Excellent
Lasso	0.8912	0.0225	0.1332	0.0147	0.0884	Excellent
Random Forest	0.8859	0.0238	0.1362	0.0147	0.0903	Excellent
Gradient Boosting	0.8977	0.0204	0.1292	0.0137	0.0859	Excellent ★




Figura 5: Confronto R^2 medio e RMSE medio tra i quattro modelli (5-Fold CV). Il modello migliore è evidenziato in arancione.




Figura 6: Permutation Importance (top-15 feature numeriche) con barre di errore standard.

5.5 Analisi degli Errori e Discussione

Il **Gradient Boosting** risulta il modello migliore su tutte e tre le metriche: $R^2=0.8977$, $RMSE=0.1292$, $MAE=0.0859$, con la deviazione standard più bassa (± 0.0204). Questo indica non solo accuratezza superiore ma anche maggiore stabilità tra i fold, a testimonianza di una migliore generalizzazione. Questo risultato è coerente con la letteratura sui dataset tabulari strutturati, dove il boosting sequenziale con shrinkage supera sistematicamente le alternative.

Ridge e Lasso producono risultati quasi identici ($R^2=0.8912$ per entrambi, $RMSE$ che differisce solo al quarto decimale). Questa convergenza indica che il dataset non è particolarmente sparso dopo la feature selection: Lasso con α basso non azzerava molti coefficienti, e le due penalizzazioni si equivalgono. La buona performance dei modelli lineari ($R^2 > 0.89$) conferma che le relazioni tra le 40 feature selezionate e il target log-trasformato hanno una componente lineare molto pronunciata. Il Random Forest risulta il peggiore dei quattro ($R^2=0.8859$) con la varianza più alta (± 0.0238), spiegabile con la maggiore sensibilità dell'algoritmo alla composizione specifica di ciascun fold.

Un valore di $RMSE=0.1292$ in scala logaritmica corrisponde a un errore medio di circa $\pm 13.8\%$ sul prezzo reale in dollari ($e^{0.1292} \approx 1.138$). Sulla mediana del dataset (\$163.000) questo implica un errore tipico di circa $\pm \$22.500$, performance molto buona per un problema di pricing immobiliare su dati reali.

6 Task di Clustering

6.1 Obiettivo e Approccio

Il task di clustering si colloca nell'ambito dell'apprendimento non supervisionato. L'obiettivo consiste nell'individuare raggruppamenti naturali all'interno del dataset senza fare uso della variabile target SalePrice. Questo cambio di paradigma rispetto alla regressione introduce sfide metodologiche specifiche: in assenza di etichette, la qualità dei cluster non può essere misurata rispetto a una ground truth, ma deve essere valutata attraverso metriche interne di coesione e separazione.

L'algoritmo principale adottato è K-Means, con analisi complementare mediante DBSCAN. Il numero ottimale di cluster viene determinato attraverso la convergenza di tre criteri indipendenti: Elbow Method, Silhouette Score e Davies-Bouldin Index.

6.2 Preparazione dei Dati per il Clustering

6.2.1 Selezione delle Feature ad Alta Varianza

Una scelta progettuale critica riguarda il criterio di selezione delle feature per il clustering. A differenza della regressione e della classificazione, che utilizzano le 40 feature selezionate tramite Mutual Information rispetto a SalePrice_log, il clustering adotta le 15 feature numeriche con varianza più alta nel dataset preprocessato. Questa scelta è metodologicamente motivata: la Mutual Information seleziona feature predittive rispetto al target, introducendo un bias implicito in un task non supervisionato dove il target non dovrebbe influenzare la struttura dei cluster. L'utilizzo di feature ad alta varianza garantisce che la selezione sia guidata dalla variabilità intrinseca dei dati, lasciando emergere la struttura naturale senza pre-orientarla verso la distribuzione del prezzo.

6.2.2 Riduzione Dimensionale con PCA

Le 15 feature selezionate vengono sottoposte a RobustScaler, che utilizza mediana e IQR al posto di media e deviazione standard, risultando più resistente agli outlier residui dopo il clipping. La riduzione dimensionale viene effettuata mediante PCA a esattamente 3 componenti principali. La scelta di 3 componenti è esplicita e motivata: le prime tre componenti spiegano il 33.4% della varianza, catturando le strutture dimensionali dominanti; la rappresentazione tridimensionale permette la visualizzazione diretta nei piani PC1-PC2 e PC1-PC3; la riduzione da 15 a 3 feature mitiga il curse of dimensionality, che penalizza le metriche di distanza in spazi ad alta dimensionalità.




Figura 7: PCA Scree Plot — varianza spiegata per componente e cumulata sul dataset numerico grezzo (percorso EDA).

6.3 K-Means Clustering

6.3.1 Descrizione dell'Algoritmo

K-Means è un algoritmo di clustering partizionale che minimizza la somma delle distanze quadratiche intra-cluster (WCSS):

$$WCSS = \sum_i \sum_{\{x \in C_i\}} \|x - \mu_i\|^2$$

dove μ_i rappresenta il centroide del cluster i-esimo. L'algoritmo procede iterativamente alternando una fase di assegnazione e una di aggiornamento dei centroidi. Sebbene K-Means garantisca la convergenza, la soluzione dipende dall'inizializzazione: questo rischio è mitigato tramite $n_{init}=100$ inizializzazioni multiple, che riducono drasticamente la probabilità di convergenza a un minimo locale.

6.3.2 Determinazione del Numero Ottimale di Cluster

La scelta di $k=3$ è supportata dalla convergenza di tre criteri indipendenti, illustrati nella Figura 8:

- **Elbow Method:** la curva del WCSS mostra un gomito pronunciato in corrispondenza di $k=3$, oltre il quale i benefici marginali in termini di riduzione dell'inerzia diminuiscono sensibilmente.
- **Silhouette Score:** raggiunge il valore massimo per $k=3$ (Silhouette=0.8776), indicando la migliore coesione intra-cluster e separazione inter-cluster.
- **Davies-Bouldin Index:** assume il valore minimo per $k=3$ (DBI=0.2415), confermando la qualità della soluzione clustering.




Figura 8: Determinazione del k ottimale — Elbow Method, Silhouette Score e Davies-Bouldin Index con indicazione della soluzione $k=3$.

6.3.3 Configurazione Finale

Il modello K-Means finale è stato addestrato con i seguenti parametri: $n_clusters=3$, $n_init=100$, $max_iter=500$, $random_state=42$. La convergenza è stata raggiunta in un numero limitato di iterazioni, indicando una struttura cluster stabile nei dati.




Figura 9: Visualizzazione dei cluster K-Means ($k=3$) nei piani $PC1-PC2$ e $PC1-PC3$. I centroidi sono indicati con il simbolo X rosso.

6.4 Valutazione del Clustering

Metrica	Valore	Interpretazione
Silhouette Score	0.8776	Eccellente (soglia buona: >0.50)
Davies-Bouldin Index	0.2415	Eccellente (soglia buona: <1.0)
K ottimale	3	Convergenza di tre criteri
Varianza spiegata PCA	33.4%	3 componenti principali

Il Silhouette Score di 0.8776 è eccezionalmente alto per dati reali: valori superiori a 0.7 sono considerati rari nella pratica. Il Davies-Bouldin Index di 0.2415 è anch'esso eccellente, ben al di sotto della soglia di qualità comunemente accettata di 1.0. Entrambe le metriche confermano cluster compatti e ben separati.

6.5 Interpretazione dei Cluster e Validazione Esterna

L'analisi delle statistiche descrittive per ciascun cluster consente un'interpretazione semantica chiara:

Cluster	SalePrice medio	Profilo tipologico
Cluster 2 (entry-level)	\$139.896	Abitazioni compatte, datate, qualità inferiore
Cluster 0 (standard)	\$170.757	Dimensioni medie, qualità standard, recenti
Cluster 1 (premium)	\$224.270	Grandi dimensioni, alta qualità, costruzione moderna

La validazione esterna costituisce il risultato metodologicamente più rilevante: i cluster sono stati determinati senza utilizzare SalePrice durante il processo di clustering. Il fatto che i tre cluster risultino ordinati in modo coerente per prezzo medio crescente (\$139k → \$171k → \$224k) dimostra che le caratteristiche fisiche degli immobili — dimensioni, qualità costruttiva, età — sono sufficienti a segmentare il mercato in fasce economiche significative. Si tratta di una conferma esterna della significatività economica dei cluster individuati dall'algoritmo in assenza di supervisione. Il miglioramento rispetto alla versione precedente (Silhouette 0.457 → 0.8776) è direttamente attribuibile alla scelta più corretta delle feature: utilizzare la varianza intrinseca invece della MI ha prodotto uno spazio di clustering dove le strutture dimensionali dominanti generano cluster naturalmente più compatti e separati.

6.6 Confronto con DBSCAN

Come analisi complementare è stato applicato DBSCAN con grid search su $\text{eps} \in [0.3, 2.0]$ e $\text{min_samples} \in \{3, 5, 10\}$. L'algoritmo ha prodotto metriche inferiori e maggiore instabilità rispetto a K-Means, con una quota significativa di osservazioni classificate come noise (label = -1). Per il dataset Ames Housing, K-Means risulta preferibile grazie alla struttura globulare dei cluster — condizione in cui K-Means è ottimale — e alla maggiore interpretabilità dei centroidi.

6.7 Discussione

Il task di clustering evidenzia l'esistenza di una struttura latente molto netta nel dataset Ames Housing. La segmentazione ottenuta riflette in modo coerente la stratificazione reale del mercato immobiliare e risulta allineata con intuizioni di dominio consolidate. I risultati confermano che le caratteristiche fisiche e qualitative degli immobili contengono informazione sufficiente a identificare automaticamente segmenti di mercato economicamente significativi, anche in assenza di qualsiasi supervisione da parte della variabile prezzo.

7 Task di Classificazione

7.1 Obiettivo e Strategia

Il task di classificazione completa il percorso metodologico iniziato con la regressione e proseguito con il clustering. In questo contesto, l'obiettivo non è più la stima puntuale del prezzo di vendita, bensì l'assegnazione di ciascuna proprietà a una fascia di prezzo discreta: Low, Medium, High. Rispetto alla regressione, la classificazione introduce una discretizzazione della variabile target che comporta una perdita informativa inevitabile. Tuttavia, tale semplificazione risulta spesso vantaggiosa in contesti applicativi in cui la distinzione tra fasce di prezzo è più rilevante di un valore continuo preciso.

7.2 Creazione delle Classi Target

La discretizzazione viene effettuata applicando *pd.qcut* con $q=3$ sulla distribuzione di *SalePrice_log*: il 33° e il 67° percentile delimitano tre classi di uguale frequenza. L'utilizzo dei quantili invece di soglie fisse in scala originale è motivato da due ragioni: garantisce classi bilanciate per costruzione, eliminando la necessità di tecniche di oversampling o undersampling; opera in scala logaritmica, coerentemente con la trasformazione del target adottata per gli altri task.

Classe	Label	Fascia di mercato	Osservazioni
0	Low	Entry-level: abitazioni compatte o da ristrutturare	981
1	Medium	Core market: case familiari standard	980
2	High	Premium/luxury: grandi dimensioni, alta qualità	969

7.3 Bilanciamento delle Classi

La distribuzione delle osservazioni tra le tre classi risulta quasi perfettamente uniforme, con un class balance ratio pari a 0.988. Questo colloca il dataset nella categoria dei dataset perfettamente bilanciati: in tale scenario, l'accuracy può essere interpretata come metrica affidabile della capacità discriminativa del modello, e non è necessario ricorrere a tecniche di bilanciamento artificiale. L'assenza di tali interventi preserva l'integrità dei dati originali ed evita l'introduzione di rumore o campioni sintetici.

7.4 Configurazione del Modello e Validazione

Per il task di classificazione è stato adottato un Random Forest Classifier con 200 alberi, in continuità con il task di regressione per garantire comparabilità metodologica. La valutazione è stata effettuata tramite validazione incrociata a 5 fold. Le predizioni di tutti i fold vengono aggregate per produrre un classification report e una matrice di confusione globali sull'intero dataset, più informativi delle sole medie fold-wise.

7.5 Risultati e Metriche di Valutazione

Metrica	Valore	$\pm$ std	Note
Accuracy	84.81%	$\pm 1.86\%$	vs baseline 33.48%
F1-Score (weighted)	84.82%	$\pm 1.85\%$	Excellent
Class Balance Ratio	0.988	—	Bilanciamento quasi perfetto
Guadagno vs baseline	+51.3 pp	—	Punti percentuali

Classe	Precision	Recall	F1-Score	Support
Low (0)	0.86	0.88	0.87	981
Medium (1)	0.77	0.77	0.77	980
High (2)	0.91	0.89	0.90	969
Weighted avg	0.85	0.85	0.85	2930

7.6 Analisi della Matrice di Confusione




Figura 10: Matrice di Confusione aggregata sui 5 fold (2930 osservazioni totali).

Il pattern degli errori è interpretabile e teoricamente coerente: le classi estreme (Low e High) sono le meglio classificate ($F1=0.87$ e $F1=0.90$), mentre la classe Medium presenta la performance più bassa ($F1=0.77$). Questa graduazione riflette la natura della discretizzazione: le proprietà entry-level e premium hanno caratteristiche fisiche distintive agli estremi della distribuzione, mentre la classe Medium raccoglie le case nella fascia centrale con confini arbitrari su entrambi i lati. Gli errori gravi (Low classificato come High o viceversa) sono rari, circoscritti a circa il 5% delle osservazioni delle classi estreme. La maggior parte delle misclassificazioni coinvolge classi adiacenti, comportamento atteso e compatibile con la natura continua del mercato immobiliare.

Il miglioramento rispetto alla versione precedente dello script (+6.6 punti percentuali di accuracy: 78.2% → 84.8%) è interamente attribuibile all'introduzione dell'One-Hot Encoding per le variabili categoriche a bassa cardinalità. Feature come KitchenQual, ExterQual, BsmtQual — indicatori di qualità con correlazione con SalePrice superiore a 0.6 — venivano precedentemente ignorati.

7.7 Discussione e Implicazioni

La principale lezione emersa dal task di classificazione riguarda il trade-off tra rappresentazione continua e discreta del prezzo. La discretizzazione introduce una perdita informativa che si manifesta soprattutto nei casi prossimi ai confini di classe. Circa il 40% degli errori coinvolge proprietà molto vicine alle soglie di quantile, suggerendo che tali misclassificazioni riflettono più l'arbitrarietà del binning che reali fallimenti predittivi del modello.

Nonostante ciò, la classificazione offre vantaggi complementari rispetto alla regressione: una maggiore interpretabilità per stakeholder non tecnici, un migliore allineamento con decisioni intrinsecamente categoriche (es. fascia di mutuo, target di marketing), e la possibilità di comunicare l'incertezza mediante probabilità di classe. Con accuracy dell'84.8% e $F1=0.848$, il modello si dimostra adeguato come strumento di segmentazione e supporto decisionale.

8 Sintesi Comparativa

8.1 Confronto delle Performance tra i Task

Task	Metrica primaria	Valore	Metrica secondaria	Valore	Verdict
Regressione (GBM)	R^2	0.8977	RMSE (log)	0.1292	Excellent
Clustering	Silhouette	0.8776	Davies-Bouldin	0.2415	Excellent
Classificazione	F1-Score (w)	0.8482	Accuracy	0.8481	Good

L'analisi comparativa dei tre paradigmi consente di trarre una visione d'insieme sulle capacità informative del dataset Ames Housing. Tutti e tre i task producono risultati nella fascia alta delle rispettive metriche. La graduazione regressione $\geq$ clustering $>$ classificazione è coerente con la natura del dataset e con le caratteristiche intrinseche dei paradigmi analitici.

8.2 Punti di Forza dei Diversi Paradigmi

Nel caso della regressione, il principale vantaggio risiede nell'allineamento naturale con il fenomeno studiato: il prezzo immobiliare è una variabile intrinsecamente continua e la regressione consente di modellarlo senza introdurre discretizzazioni artificiali. Il confronto tra quattro modelli ha evidenziato la superiorità del Gradient Boosting, confermando che il boosting sequenziale con shrinkage rappresenta lo stato dell'arte per dataset tabulari.

Il clustering, pur operando in assenza di supervisione, presenta punti di forza di natura esplorativa. I cluster individuati risultano semanticamente interpretabili e allineati con segmentazioni consolidate del mercato immobiliare. La validazione ex-post tramite SalePrice conferma che i cluster catturano una reale stratificazione economica, nonostante il prezzo non sia stato utilizzato durante il processo.

La classificazione si distingue per la capacità di supportare decisioni categoriali dirette. Il bilanciamento naturale delle classi elimina problematiche tipiche della classificazione, mentre il pattern degli errori — dominato da confusioni tra classi contigue e rarità di errori estremi — indica che il modello cattura correttamente l'ordinamento sottostante delle fasce di prezzo.

8.3 Idoneità del Dataset ai Diversi Task

Per la regressione, l'idoneità è eccellente: $R^2=0.8977$ supera ampiamente le soglie comunemente accettate per problemi socio-economici complessi. La ricchezza di feature predittive, la qualità del preprocessing e la stabilità cross-fold concorrono a rendere il dataset particolarmente adatto a questo tipo di analisi.

Per il clustering, l'idoneità è anch'essa eccellente, grazie alla scelta metodologica corretta delle feature per varianza intrinseca. Il dataset presenta una struttura cluster netta (Silhouette=0.8776) con segmenti economicamente interpretabili.

Per la classificazione, l'idoneità è buona. L'accuracy del 84.8% rappresenta una performance solida per un problema a tre classi equiprobabili. La classe Medium si conferma la più problematica, a causa della sua ambiguità intrinseca ai confini di binning.

8.4 Key Findings Cross-Task

L'analisi comparativa consente di identificare evidenze trasversali fondamentali. In primo luogo, poche feature aggregate — in particolare TotalSF, Overall Qual e Neighborhood — catturano la maggior parte dell'informazione predittiva in tutti i task. Questo suggerisce che dimensione, qualità e localizzazione rappresentano i driver fondamentali del valore immobiliare, indipendentemente dal paradigma analitico adottato.

In secondo luogo, emerge una struttura latente con transizioni graduali piuttosto che discrete tra segmenti, riflettendo la natura continua del mercato immobiliare. Questa caratteristica limita inevitabilmente le performance dei metodi che impongono segmentazioni rigide, spiegando perché la classificazione — pur ottima in assoluto — risulti inferiore alla regressione.

8.5 Raccomandazioni Strategiche

Alla luce dell'analisi comparativa, si raccomanda un approccio multi-paradigma. Per applicazioni operative di valutazione immobiliare, il Gradient Boosting Regressor dovrebbe costituire il metodo primario, con un errore tipico del $\pm 13.8\%$ sul prezzo reale. La classificazione rappresenta un'alternativa valida per screening rapido e comunicazione semplificata con stakeholder non tecnici. Il clustering dovrebbe essere utilizzato nelle fasi iniziali di esplorazione o come strumento di segmentazione preliminare indipendente dal target.

9 Conclusioni

9.1 Riepilogo del Lavoro Svolto

Il presente lavoro ha condotto un'analisi multi-paradigma completa del dataset Ames Housing attraverso regressione supervisionata, clustering non supervisionato e classificazione multi-classe. L'obiettivo non è stato l'applicazione meccanica di algoritmi standard, ma una valutazione critica e comparativa dell'idoneità del dataset rispetto a ciascuna prospettiva analitica, mettendo in relazione scelte metodologiche, caratteristiche dei dati e risultati ottenuti.

La fase di ETL e preprocessing ha rappresentato lo snodo centrale dell'intero lavoro. Il feature engineering guidato dalla conoscenza del dominio immobiliare ha prodotto variabili aggregate come TotalSF e temporali come HouseAge, entrambe emerse tra le prime dieci feature per Mutual Information. La gestione corretta delle variabili categoriche tramite One-Hot Encoding — assente nella versione precedente dello script — ha determinato miglioramenti misurabili in tutti i task supervisionati.

Nel task di regressione, il confronto tra quattro modelli ha evidenziato la superiorità del Gradient Boosting ($R^2=0.8977$), con un errore medio del $\pm 13.8\%$ sul prezzo reale. Il clustering ha rivelato una struttura latente eccezionalmente netta (Silhouette=0.8776), con tre segmenti di mercato ordinati per prezzo crescente pur senza aver utilizzato il target durante il processo. La classificazione ha raggiunto accuracy e F1 dell'84.8%, con errori concentrati tra classi adiacenti e rarità di errori gravi.

9.2 Valutazione Complessiva del Dataset

Considerando l'intero percorso analitico, il dataset Ames Housing si conferma eccellente per la regressione, eccellente per il clustering con la corretta selezione delle feature, e molto buono per la classificazione. Questa graduazione riflette la natura intrinsecamente continua del fenomeno studiato: il mercato immobiliare non ha confini netti tra segmenti, ma una struttura gradiente dove la regressione sfrutta al massimo l'informazione continua del target.

Un elemento trasversale emerso con forza è l'importanza del preprocessing e del feature engineering. In tutti i task, le scelte operate in queste fasi preliminari hanno avuto un impatto maggiore rispetto alla selezione fine degli algoritmi, confermando che la qualità dei dati è spesso il fattore determinante del successo modellistico.

9.3 Contributi Metodologici e Limitazioni

I principali contributi metodologici del presente lavoro sono: (i) l'introduzione dell'One-Hot Encoding corretto che ha recuperato informazione predittiva da feature categoriche precedentemente ignorate; (ii) la scelta delle feature per varianza intrinseca nel clustering, metodologicamente più corretta rispetto alla MI per task non supervisionati; (iii) il

confronto sistematico di quattro modelli di regressione che ha consentito di identificare il Gradient Boosting come best performer; (iv) la validazione esterna dei cluster attraverso il prezzo medio, che ha confermato la significatività economica dei segmenti individuati.

Le limitazioni principali riguardano l'assenza di ottimizzazione sistematica degli iperparametri, l'utilizzo di un dataset geograficamente e temporalmente circoscritto (Ames, Iowa, 2006-2010) che limita la trasferibilità dei modelli, e l'assenza di analisi dell'interpretabilità tramite valori SHAP. Queste rappresentano naturali direzioni di estensione futura.

In conclusione, il lavoro ha dimostrato che il massimo valore analitico si ottiene adottando un approccio complementare che integri più paradigmi: la regressione per l'accuratezza predittiva massima, la classificazione per l'interpretabilità categoriale, il clustering per la scoperta di strutture latenti indipendenti dal target.

Riferimenti Bibliografici

- [1] D. De Cock, *Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project*, Journal of Statistics Education, vol. 19, no. 3, 2011.
- [2] S. García, J. Luengo, F. Herrera, *Data Preprocessing in Data Mining*, Springer, 2015.
- [3] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning*, Springer, 2009.
- [4] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [5] I. T. Jolliffe, *Principal Component Analysis*, Springer, 2002.
- [6] R. Kohavi, *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*, IJCAI, 1995.
- [7] F. Pedregosa et al., *Scikit-learn: Machine Learning in Python*, JMLR, 2011.

Riepilogo Comparativo delle Performance

Task	Metrica primaria	Valore	Metrica secondaria	Valore	Terziaria	V e r d i c t
Regressione (GBM)	R ²	0.8977	RMSE (log)	0.1292	MAE=0.0859	E x c e l l e n t
Clustering	Silhouette	0.8776	Davies-Bouldin	0.2415	k=3	E x c e l l e n t
Classificazione	F1-Score (w)	0.8482	Accuracy	0.8481	Bal.=0.988	G o o d